IMT2200

INTRODUCCIÓN A CIENCIA DE DATOS

2021-2

INTRODUCCIÓN A CIENCIA DE DATOS

CLASE 1

AGENDA DE HOY

- Bienvenida
- ¿De qué se trata el curso?
- Programa y planificación del curso
- Próximos pasos

¿Qué es la Ciencia de Datos?

CIENCIA Y CIENCIA DE DATOS

¿Qué entendemos por ciencia?

- Estudio sistemático de la estructura y comportamiento del mundo físico y natural, mediante la **observación y experimentación**.

- Foco: relaciones de **causalidad ➔ ¿Por qué?**

- En la medida que abordamos problemas cada vez más complejos, la ciencia requiere un enfoque interdisciplinario para identificar las hipótesis, análisis y relaciones de causalidad correctas.

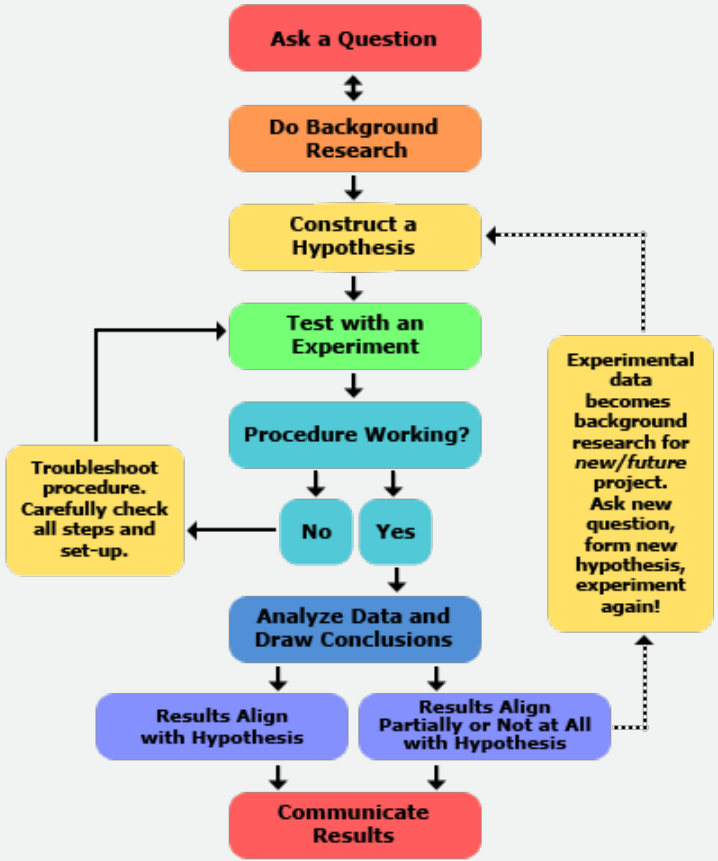

DATA AGE: LA DIGITIZACIÓN DEL MUNDO

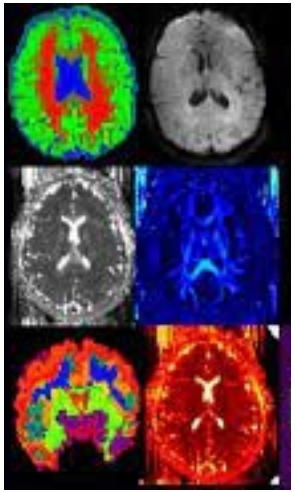

#US44413318

The data-driven world will be **always on**, **always tracking**, **always monitoring**, **always listening** and **always watching** – **because it will be always learning**.

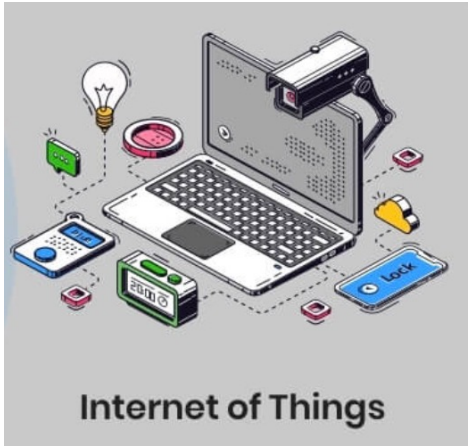

Reinsel, D.; Gantz, J.; Rydning, J.; (2018) “The Digitization of the World: From Edge to Core”, IDC White Paper, #US44413318

DATA AGE: LA DIGITIZACIÓN DEL MUNDO

"Datósfera Global":
Una medida de toda la nueva data que es capturada, creada y replicada en un cierto año en el planeta.

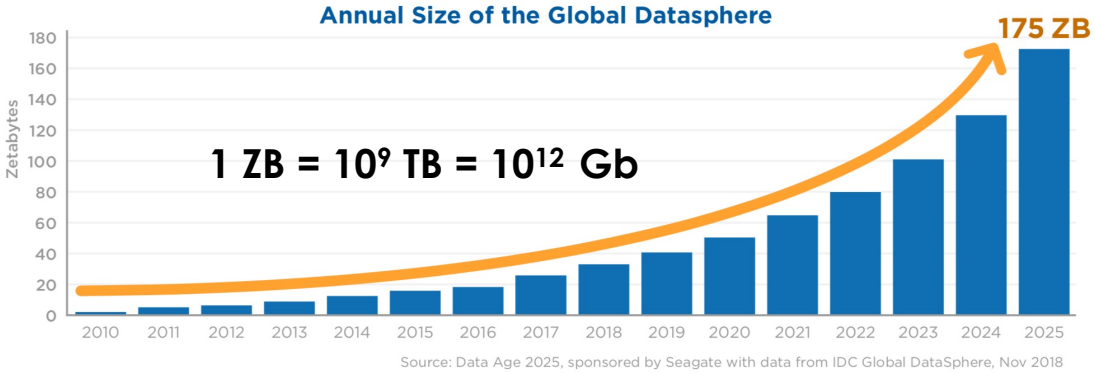

¿DÓNDE SE GENERAN Y ALMACENAN ESTOS DATOS?

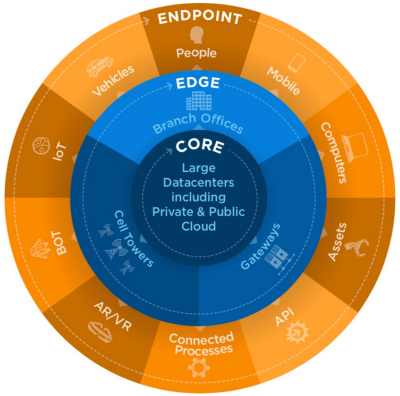

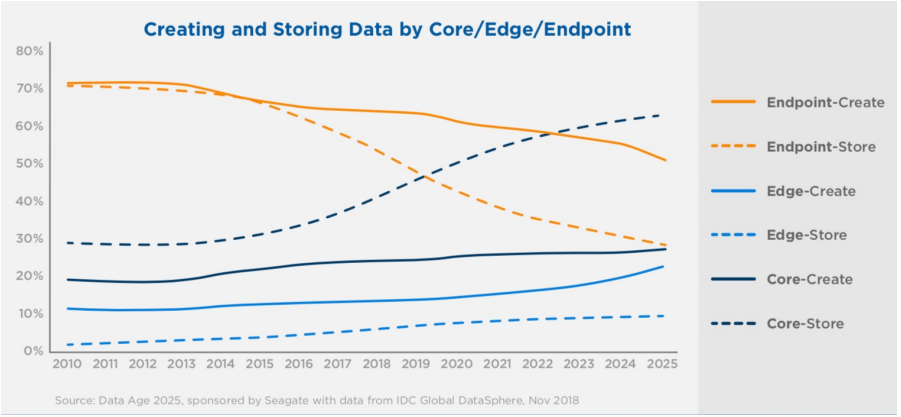

Reinsel, D.; Gantz, J.; Rydning, J.; (2018) "The Digitization of the World: From Edge to Core", IDC White Paper, #US44413318

CIENCIA DE DATOS: DEFINICIONES SENCILLAS

- "Es la ciencia de extraer información significativa de los datos"

- Procesos y técnicas involucrados en la transformación de estos recursos (big data) en información y conocimiento.

- Es el proceso de formular una pregunta cuantitativa, que puede ser respondida con datos,
  - Recolectando y limpiando los datos
  - Analizando los datos, y
  - Comunicando la respuesta a la pregunta a una audiencia relevante.

- Foco está en correlaciones y patrones, más que en causalidad.

¿QUÉ ES LA CIENCIA DE DATOS?

¿Es Ciencia de Datos lo mismo que trabajar con “Big Data”?

BIG DATA:

Algunas propiedades fundamentales (VVV):

- Gran volumen
- Gran velocidad (ej: tiempo real)
- Gran variedad: estructurada y no estructurada
- Veracidad, valor….

- Es una definición relativa: ***“es Big Data cuando no puede ser contenida en una sola unidad de cómputo”***

  (David Cranshaw, Google)

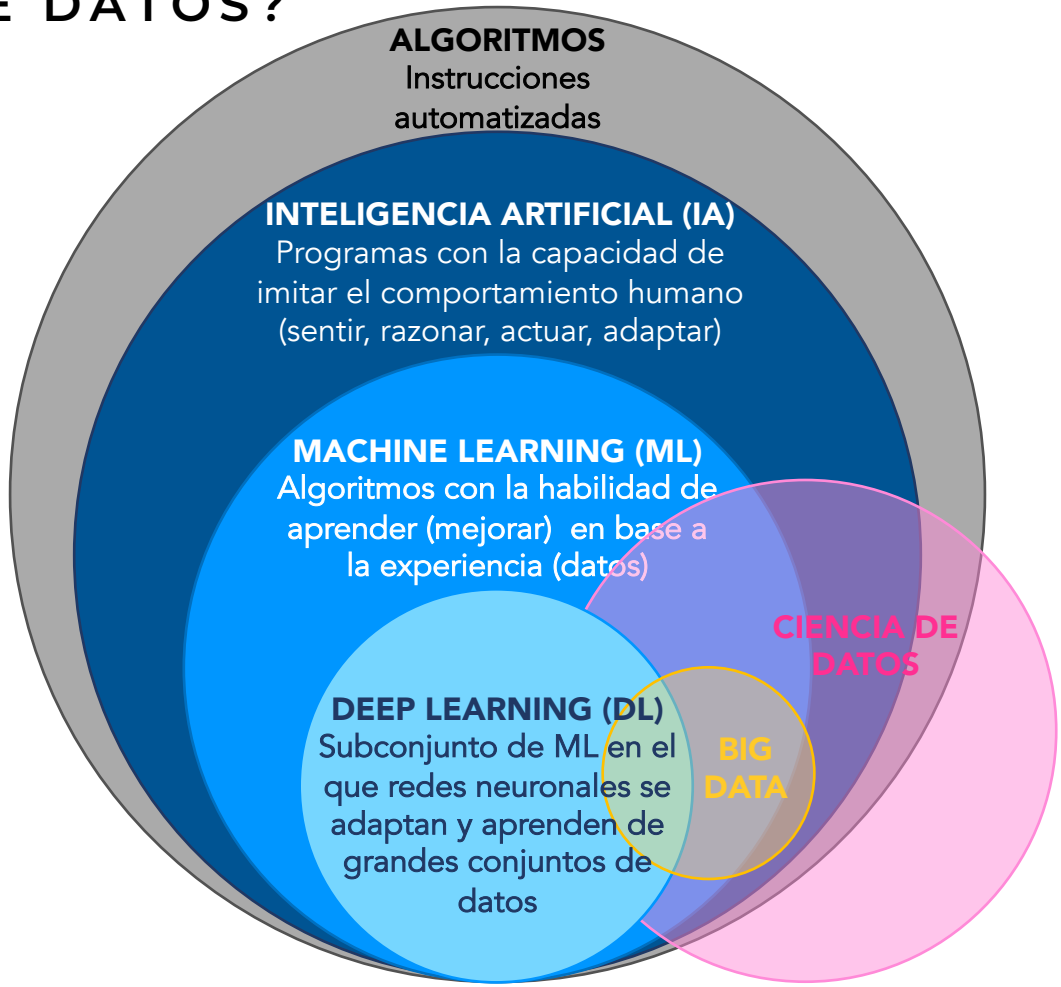

EL PROCESO DE CIENCIA DE DATOS

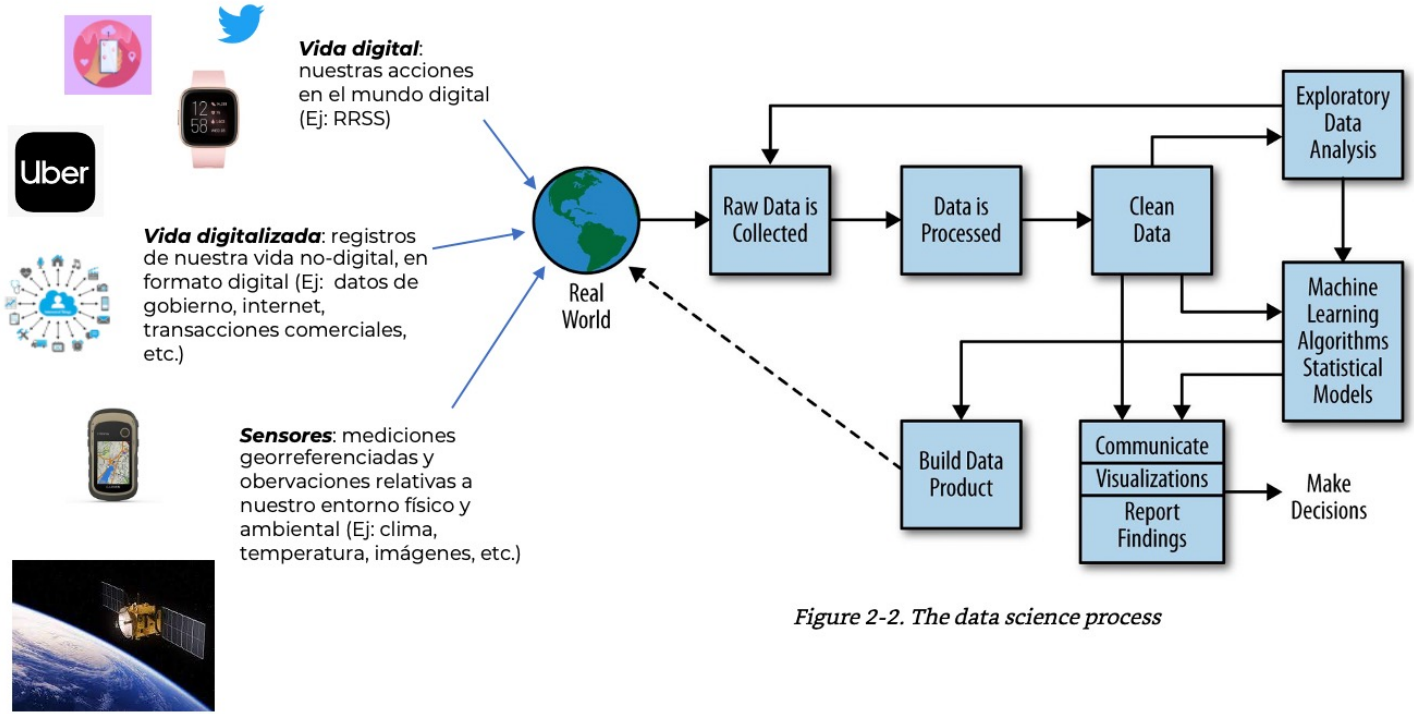

Figure 2-2. The data science process

¿QUÉ ES UN CIENTISTA DE DATOS?

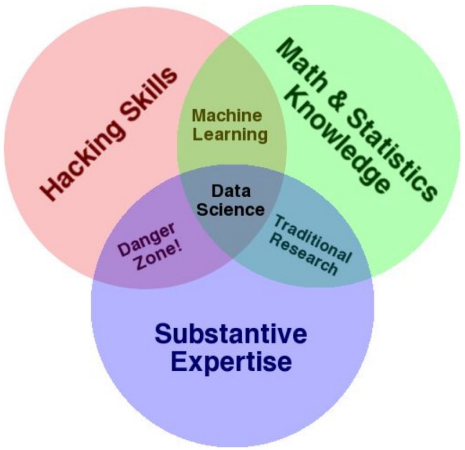

Figure 1-1. Drew Conway's Venn diagram of data science

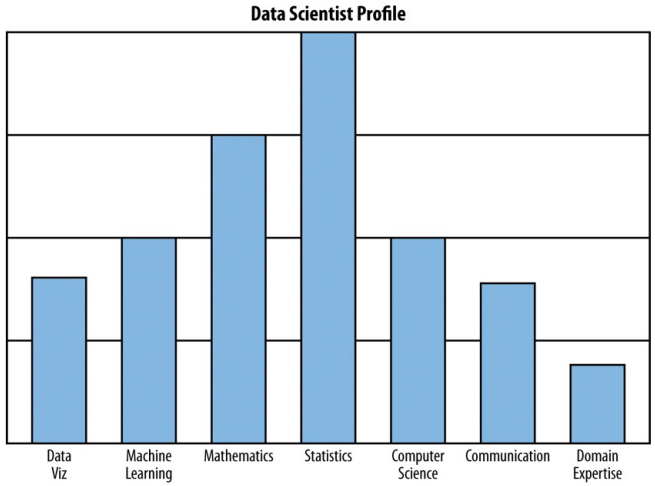

Se requiere una **combinación de competencias** o conocimientos

- Estadística y modelación matemática
- Computación / programación
- Visualización y comunicación
- Conocimiento específico del campo de estudio
- Trabajo **colaborativo**

¿QUÉ ES UN CIENTISTA DE DATOS?

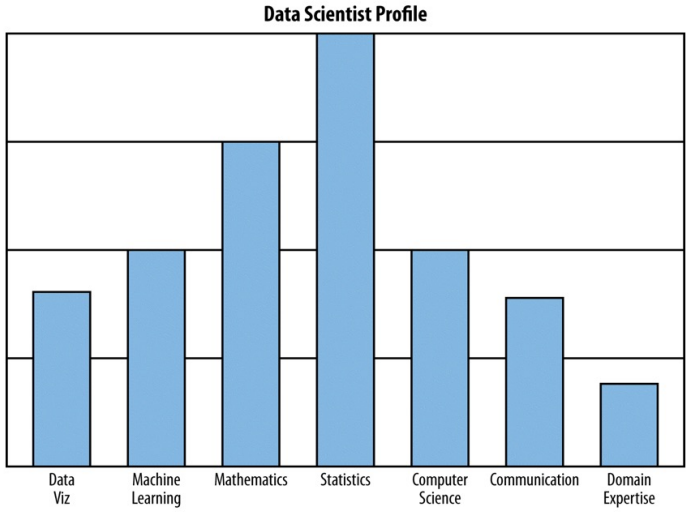

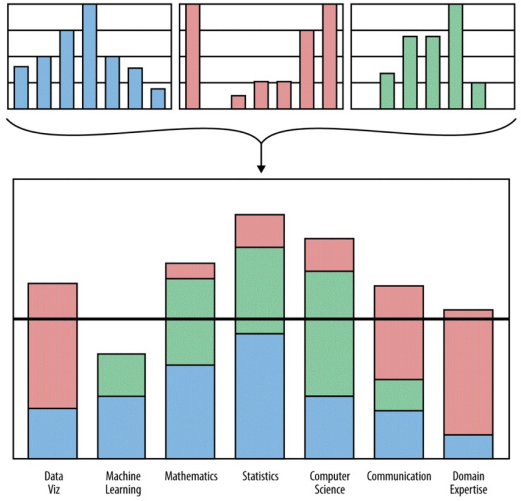

Perfiles individuales

Equipo

Se requiere una **combinación de competencias** o conocimientos

- Estadística y modelación matemática
- Computación / programación
- Visualización y comunicación
- Conocimiento específico del campo de estudio
- Trabajo **colaborativo**

¿QUÉ ES UN CIENTISTA DE DATOS?

http://nirvacana.com/thoughts/2013/07/08/becoming-a-data-scientist/

PROGRAMA DEL CURSO

INFORMACIÓN GENERAL

PÁGINA WEB: https://imt2200.github.io

- Programa del curso
- Calendario
- Material de clases
- Grabaciones
- Material complementario

➔ REVISAR CON FRECUENCIA

GITHUB:

- Tareas y proyecto

CANVAS:

- Anuncios
- Calificaciones
- Foros

Pontificia Universidad Católica de Chile
Instituto de Ingeniería Matemática y Computacional
Semestre 2021-2

IMT2200 - Introducción a Ciencia de Datos
Programa del Curso

1 Información General

- **Profesora**: Paula Aguirre Aparicio (paaguirr@ing.puc.cl)
- **Ayudantes**:
  - Ayudante de Cátedra: Vicente Agüero (vicenteaguero@uc.cl)
  - Ayudante Corrector: TBD
- **Horarios**:
  - Cátedra: M-J:2
  - Ayudantía: W:3
  - Horario de consultas profesora (por Zoom o presencial): W 16:00 - 17:00 hrs.
- **Página web**: `https://imt2200.github.io/`

2 Descripción del Curso

Las organizaciones utilizan sus datos para apoyar la toma de decisiones, y para desarrollar productos y servicios intensivos en datos. El conjunto de competencias requeridas para apoyar estas funciones se ha agrupado bajo el término Ciencia de Datos. En este curso los estudiantes analizarán la importancia de este campo y su crecimiento exponencial, describiendo sus principios básicos y las principales técnicas y herramientas utilizadas. Los estudiantes aprenderán sobre recolección e integración de datos, análisis exploratorio de datos, análisis descriptivo y predictivo, y creación de productos de información.

3 Resultados de Aprendizaje

Al finalizar este curso, los estudiantes habrán logrado los siguientes aprendizajes:

1. Describir lo que es la ciencia de datos, y su importancia para la ciencia, sociedad y negocios.
2. Identificar los conjuntos de habilidades necesarios para ser un científico de datos.
3. Identificar problemas éticos y de privacidad que emergen en ciencia de datos.
4. Explicar las etapas y tareas que forman parte del ciclo de vida de un proyecto de ciencia de datos.
5. Reconocer distintos tipos y formatos de datos estructurados y no estructurados.
6. Desarrollar el proceso de extracción, transformación y carga de datos para un proyecto sencillo de ciencia de datos.
7. Identificar los fundamentos matemáticos y estadísticos para el análisis exploratorio y modelamiento estadístico en un proyecto de ciencia de datos.

CLASES Y AYUDANTÍAS

CLASES

- Horario: M-J:2 (10:00-11:20)
- PRESENCIALES DESDE EL 20 DE SEPTIEMBRE

AYUDANTÍAS

- Ayudante: **Vicente Agüero** (vicenteaguero@uc.cl)
- Horario: W:3 (11:30-12:50)
- REMOTAS DURANTE TODO EL SEMESTRE

- Todas las clases y ayudantías serán grabadas y publicadas en la página del curso

EVALUACIONES

TAREAS (NT):

- 4 tareas **individuales** de programación enfocadas en las distintas etapas del proceso de CD.
- Entrega a través de repositorio GitHub personal de cada estudiante.

$$NT = \frac{T_1 + T_2 + T_3 + T_4}{4}$$

CONTROLES (NC):

- ~12 controles breves (10') sobre contenidos del curso ➔ ~48 preguntas
- Al final de la clase, a través de Canvas o presencial.
- Se elimina el 25% de las preguntas del semestre.
- No se recuperan inasistencias.

$$NC = \frac{\sum P_i}{N_p} \cdot 6 + 1$$

EVALUACIONES

PROYECTO (NP):

- Proyecto **grupal** de aplicación, en el cual los estudiantes deberán desarrollar el proceso completo de ciencia de datos para resolver una pregunta sobre algún tema a su elección.
- Tres entregables:
  - Propuesta (20%)
  - Repositorio y pagina GitHub (60%)
  - Presentación visual (20%)
- Entrega de enunciado y detalles próxima semana.

NOTA FINAL (NF):

$$\boxed{NF = 0.5 \cdot NP + 0.3 \cdot NT + 0.2 \cdot NC}$$

EVALUACIONES: FECHAS

Tareas	
T0	20/8/2021
T1	30/8/2021
T2	24/9/2021
T3	29/10/2021
T4	29/11/2021

Controles	
Q0	24/8/2021
Q1	31/8/2021
Q2	7/9/2021
Q3	14/9/2021
Q4	21/9/2021
Q5	28/9/2021
Q6	5/10/2021
Q7	12/10/2021
Q8	2/11/2021
Q9	9/11/2021
Q10	16/11/2021
Q11	23/11/2021
Q12	30/11/2021

Proyecto	
Propuesta	15/10/2021
Entrega final	14/12/2021
Presentaciones	14/12/2021

BIBLIOGRAFÍA

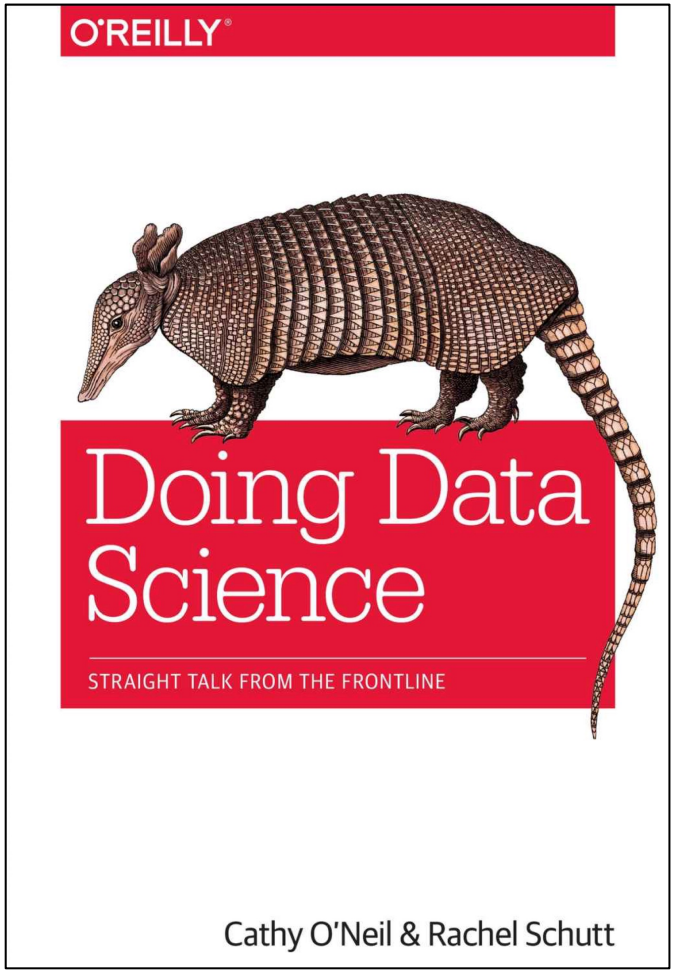

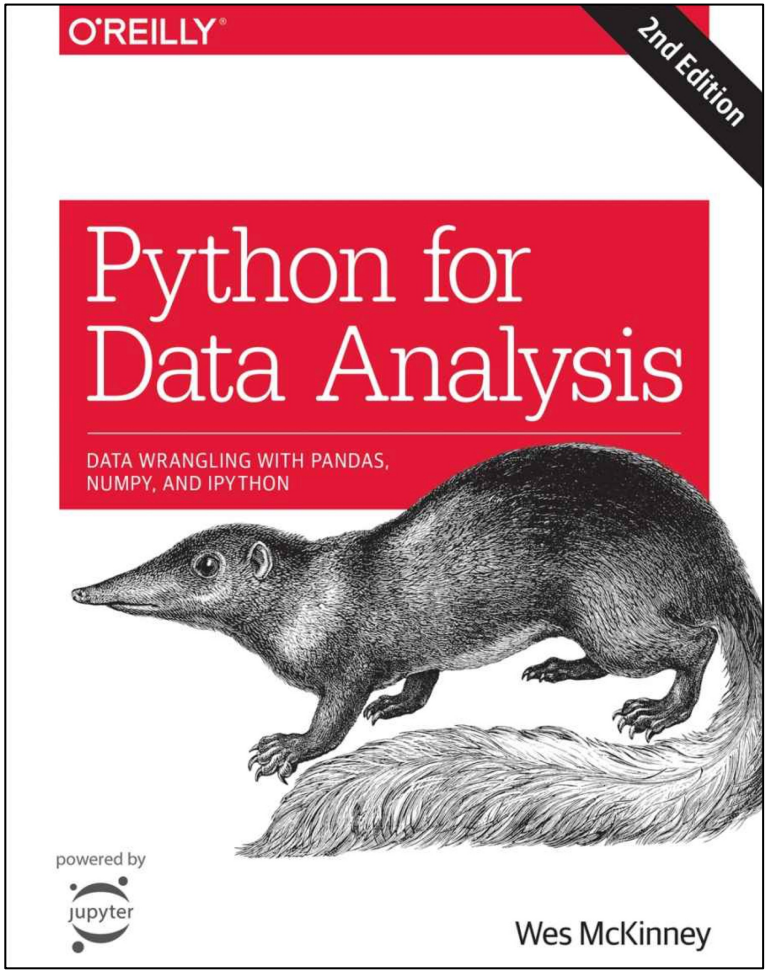

PRÓXIMOS PASOS

- Crear cuenta personal en GitHub

- Hoy:
  - Enviar información de la cuenta a través de formulario en Canvas (disponible desde las 15:00 hrs.)
  - Recibirá una invitación a unirse al repositorio privado del curso, y a realizar la Tarea 0 (prueba).

- Mañana: Ayudantía
  - Configuración de entorno de instalación y herramientas básicas de programación.

- Jueves: Clases
- Viernes:
  - Entrega Tarea 0 (GitHub)
  - Publicación Tarea 1